

Accelerated edge computing for Neural Networks

Arno PLAETINCK

Promotor: Prof. Dr. Ir. Nobby Stevens

Co-promotoren: Ing. Willem Raes
Ing. Jorik De Bruycker

Masterproef ingediend tot het behalen van
de graad van master of Science in de
industriële wetenschappen: Industriële
Ingenieurswetenschappen Elektronica-ICT
Embedded Systems

©Copyright KU Leuven

Zonder voorafgaande schriftelijke toestemming van zowel de promotor(en) als de auteur(s) is overnemen, kopiëren, gebruiken of realiseren van deze uitgave of gedeelten ervan verboden. Voor aanvragen i.v.m. het overnemen en/of gebruik en/of realisatie van gedeelten uit deze publicatie, kan u zich richten tot KU Leuven Technologicampus Gent, Gebroeders De Smetstraat 1, B-9000 Gent, +32 92 65 86 10 of via e-mail iiw.gent@kuleuven.be.

Voorafgaande schriftelijke toestemming van de promotor(en) is eveneens vereist voor het aanwenden van de in deze masterproef beschreven (originele) methoden, producten, schakelingen en programma's voor industrieel of commercieel nut en voor de inzending van deze publicatie ter deelname aan wetenschappelijke prijzen of wedstrijden.

Dankwoord

In deze thesis wordt een benchmark voorgesteld die de performantie van verscheidene edge devices analyseert op vlak van latency. De uitvoering van verschillende getrainde neurale netwerken wordt vergeleken met parameters zoals processorgebruik, klokfrequentie, prijs en energieverbruik. De verworven inzichten kunnen toegepast worden in allerlei low-latency applicaties zoals zelfrijdende voertuigen.

Verder had ik graag de mensen bedankt die geholpen hebben deze thesis tot stand te brengen. Hulp van personen zoals mijn promotor Prof. Dr. Ir. Nobby Stevens en de co-promotoren Ing Willem Raes en Ing Jorik De Bruycker werd zeer geapprecieerd.

Abstract

Benchmark voor latency bij edge-devices.

Er is een hele grote verscheidenheid aan onderwerpen waar de tijdsduur van executie van groot belang is. Hiervoor wordt vaak een afweging gemaakt tussen cloud en edge computing. In de cloud kan er met krachtige en snelle hardware worden gewerkt, maar is er wel een significante vertraging veroorzaakt door het verzenden van data over het internet. Uitvoeren van programma's in de edge hebben geen last van deze vertraging. Dit kan voordelig zijn bij latency-gevoelige applicaties zoals het zelfstandig rijden van voertuigen.

Deze scriptie bespreekt een benchmark van drie verschillende edge-toestellen en reguliere computer. Deze benchmark biedt informatie over de latency en processor-performantie van elk device. Deze zal men meer inzicht geven bij een kosten-baten analyse te maken. De onderzochte devices binnen deze thesis zijn dedicated toestellen zoals CPU-gebaseerde Google Coral Dev en Raspberry Pi en GPU-gebaseerde toestellen zoals Nvidia Jetson Nano en een Personal Computer.

Om een representatieve benchmark te bekomen is het nodig om verschillende programma's op een identieke wijze te testen. De te beproeven programma's zullen verdeeld worden over de categorieën regressie en classificatie. De data die uit de benchmark afgeleid wordt bestaat uit de latency en het processor-gebruik van het runnen van elk programma. Deze worden dan herwerkt en genormaliseerd om de resultaten eenvoudiger te analyseren. Zo worden factoren zoals prijs, kloksnelheid en energieverbruik in rekening gebracht.

Uit de resultaten kan er een duidelijk verschil afgeleid worden tussen de verschillende edge-toestellen. Hierbij komt de Nvidia Jetson Nano het best naar voor, ondanks de hogere kostprijs en een hoger energieverbruik. Wel kan er nog een argument gegeven worden voor de Google Coral Dev die in specifieke programma's met geoptimaliseerde Tensorflow Lite modellen een voordeel kan halen.

Trefwoorden: benchmark, edge-devices, latency, Jetson Nano, Coral Dev, Raspberry Pi

Inhoudsopgave

1 Inleiding	1
2 Literatuurstudie	3
2.1 Kadering	4
2.2 Artificiële Intelligentie	5
2.3 Machine Learning	6
2.3.1 Leeralgoritmes en -technieken	6
2.3.2 Keuze voor een Machine Learning-methode	12
2.3.3 Leertechnieken	15
2.4 Evolutie Single Board Computers	16
2.4.1 Geschiedenis	16
2.5 Assortiment aan 'off the shelf' toestellen	18
2.5.1 Beaglebone AI	18
2.5.2 Coral Dev Board	19
2.5.3 Nvidia Jetson Nano	19
2.5.4 Nvidia Jetson TX2	20
2.5.5 Raspberry Pi	20
2.6 Benchmarking van Machine Learning algoritmes	21
2.6.1 Bestaande benchmarks	21
3 Data verwerving	25
3.1 Verkennen van software	25
3.2 Verkennen edge-devices	25
3.3 Structuur programma	25
3.3.1 Regressie subprogramma's	25
3.3.2 Classificatie subprogramma's	29
3.3.3 Conversie naar TFLite	31
3.4 Uitvoeren metingen	31
3.5 Opslaan van data	31
4 Data verwerking	33

5 Resultaten	35
6 Conclusie	37
A Een aanhangsel	41
B Beschrijving van deze masterproef in de vorm van een wetenschappelijk artikel	43
C Poster	45

Lijst van figuren

2.1	Structuur van een Neuraal Netwerk. Afbeelding te vinden op https://github.com/drewnoff/spark-notebook-ml-labs/tree/master/labs/DLFramework . Website werd geraadpleegd op 24/12/2019	7
2.2	Algemene structuur van een node. Afbeelding te vinden op https://pathmind.com/wiki/neural-network . Website werd geraadpleegd op 23/12/2019.	8
2.3	De Sigmoid activatiefunctie. Afbeelding te vinden op https://towardsdatascience.com/activation-functions-neural-networks-1cbd9f8d91d6 . Website werd geraadpleegd op 24/12/2019.	9
2.4	Algemene structuur van een beslissingsboom. Afbeelding te vinden op https://medium.com/machine-learning-bites/machine-learning-decision-tree-classifier-9eb67cad263e . Website werd geraadpleegd op 24/12/2019.	10
2.5	Tweedimensionale Support Vector Machine. Afbeelding te vinden op https://subscription.packtpub.com/book/data-and-business-intelligence/9781788994170/5/ch05lvl1sec36/support-vector-machines . Website werd geraadpleegd op 20/12/2019.	11
2.6	Voorbeeld van Lineaire Regressie. Afbeelding te vinden op https://en.wikipedia.org/wiki/Regression-analysis . Website werd geraadpleegd op 19/12/2019.	12
2.7	Routine bij Reinforcement Learning. Afbeelding te vinden op http://webindream.com/reinforcement-learning/ . Website werd geraadpleegd op 23/12/2019.	16
2.8	Eerste Single Board Computers (SBC): MMD-1. Afbeelding te vinden op https://nl.wikipedia.org/wiki/Single_Board_Computer . Website werd geraadpleegd op 23/12/2019.	17
2.9	Modellen en resultaten van de benchmark op de Jetson Nano. Afbeelding te vinden op https://devblogs.nvidia.com/jetson-nano-ai-computing/ . Website werd geraadpleegd op 17/02/2020.	22
3.1	Praktische betekenis van het compair-subprogramma. Afbeelding te vinden op https://pyrenn.readthedocs.io/en/latest/ . Website werd geraadpleegd op 10/04/2020.	26
3.2	Enkele voorbeelden uit de FashionMNIST-dataset. Afbeelding te vinden op https://becominghuman.ai/how-to-create-a-clothing-classifier-fashion-mnist-program-on-google-colab-99f620c24fcd . Website werd geraadpleegd op 13/04/2020.	30

Lijst van tabellen

3.1	Voorbeelden van de gebruikte data voor regressiemodellen.	26
-----	---	----

Lijst van symbolen en acroniemen

Symbols

λ_{ex}	Excitation wavelength
λ_{em}	Emission wavelength
$N(\dots)$	Noise process

NOG TE DOEN OP HET EINDE VAN DE THESIS

Acronyms

LPWAN	Low-Power Wide-Area Network
IOT	Internet-of-Things
ISI	Inter-Symbol Interference
SBC	Single Board Computers
ANN	Artificiële Neurale Netwerken
ML	Machine Learning
NN	Neurale Netwerken
SOC	System On Chip
AI	Artificiële Intelligentie
EVE	embedded-vision-engine
SVM	Support Vector Machines
TPU	Tensor Processing Unit
ASIC	Application Specific Integrated Circuit
TOPS	tera operations per second
CPU	Central Processing Unit
RELU	rectified linear unit
DLIB	Deep Learning Inference Benchmarks
DL	Deep Learning
CNN	Convolutional Neural Networks
TF	Tensorflow
TFL	Tensorflow Lite
RNN	Recurrent Neural Network
CSV	Comma Separated Value
RTRL	Real Time Recurrent Learning
BPTT	Back Propagation Through Time

Hoofdstuk 1

Inleiding

De computerwereld maakt de laatste jaren grote stappen op vlak van Machine Learning[1]. Deze vorderingen werden gedreven door onder meer de nieuwste ontwikkelingen op vlak van computerrekenkracht en de vierde industriële revolutie[2]. Door de veelvuldige toepassingsmogelijkheden werd Machine Learning (ML) een populair en veelbesproken onderwerp. Tegenwoordig kan een bepaalde vorm van Artificiële Intelligentie (AI) in elke sector teruggevonden worden[3]. Van hartritmestoornissen herkennen in de medische sector tot commentaarherkenning in de toeristische stiel.

In deze thesis zal men trachten om een benchmark met AI op te stellen waarmee verschillende SBCs met elkaar vergeleken kunnen worden. Dit instrument moet meer inzicht verschaffen in welke mate machineleertechnieken toepasbaar zijn. Er zal vooral gekeken worden naar performantieparameters. Hoe groot is de latency die optreedt? Welk verbruik en complexiteit van het netwerk gaat er hier mee gepaard? Ook tussen deze hardware-opties wordt er een afweging gemaakt. Welk toestel is voordeliger in welke situatie? Is een goedkoper toestel tot evenwaardige resultaten in staat? Er zal een oplistijng gemaakt worden van de belangrijkste parameters en met behulp van de benchmark-resultaten zal er een besluit over de SBCs genomen worden.

Hoofdstuk 2

Literatuurstudie

In dit hoofdstuk zal er eerst een afgrenzing gegeven worden waarbinnen de thesis gekozen is. Vervolgens zal een korte introductie gegeven worden tot Artificiële Intelligentie en Machine Learning waarin verschillende vormen en mogelijke toepassingsdomeinen behandeld worden. De verschillende leermodellen worden bekeken en er wordt nagegaan hoe de onderdelen een werkend geheel vormen. Vervolgens wordt er een overzicht van de voor- en nadelen van de verschillende technieken gegeven. Er wordt een best bruikbare methode voor de toepassing in deze thesis gekozen. Bij deze keuze zullen de voor- en nadelen gewikt en gewogen worden. Verder wordt er ook de geschiedenis van Single Board Computers aangehaald. Hoe zijn deze toestellen ontstaan, hoe zijn ze geëvolueerd en in welke staat zijn de hedendaagse SBCs. Verder worden ook verschillende voorbeelden van SBCs besproken die in staat zijn om Machine Learning-technieken toe te passen. Deze zullen onderworpen worden aan een benchmark die in paragraaf 2.6 besproken zal worden.

2.1 Kadering

Een branche in de ML die steeds meer in de schijnwerpers staat, is de logistieke sector[4]. Door de steeds verder doorgedreven automatisatie van bedrijven, wordt er ook in bijvoorbeeld magazijnen geopteerd voor het optimaliseren van onder meer het leveren van de verschillende onderdelen en de veiligheid in het magazijn. Gebruik maken van zelfrijdende vorkheftrucks is een mogelijke optie in het verbeteren van de efficiëntie. Niet alleen in het magazijn maar ook op de weg is er een groeiende belangstelling naar zelfrijdende voertuigen, die ontwikkeld worden door grote bedrijven zoals Tesla en Uber. In beide cases zal er een zekere vorm van positiebepaling nodig zijn. Het is van groot belang dat deze bepaling zo accuraat mogelijk plaats vindt, met niet alleen een juiste locatie, maar ook een resultaat dat op zo kort mogelijke tijdsperiode geproduceerd wordt.

Deze nood aan *low latency* kan het verschil betekenen tussen een voertuig dat beslist dat hij moet vertragen of beslist dat hij veilig kan doorrijden maar toch een botsing veroorzaakt. De berekening van die cruciale locatiebepaling kan zowel in de *cloud*, als in de *edge*[5] gebeuren en gebeurt onder meer met behulp van ML. Hierbij wordt met cloud verwezen naar het verwerken van data op een locatie ver weg van het voertuig zoals serverzalen. Met edge wordt dan weer een locatie dichtbij het voertuig bedoeld. Dit kan zowel op, als vlakbij het voertuig zijn. *Cloud computing* brengt een zekere toegevoegde latency teweeg. Dit is de nodige tijd om via het internet de server te bereiken. Hierdoor zal men eerder kiezen voor *edge computing* vallen. Indien de berekeningen in de edge plaats vinden zal er bijvoorbeeld een kleinere vertraging zijn tussen het moment van vertrekken en het waarnemen door het algoritme dat er vertrokken werd. De afstand tussen de reële locatie, waar het voertuig zich fysisch ook bevindt, en de virtuele locatie, waar de computer het voertuig acht te zijn, is kleiner bij lagere latencies. Dit leidt tot een betere positiebepaling. Deze heeft dan weer tot gevolg dat meer ongevallen vermeden kunnen worden. Welke hardware men gebruikt kan variëren van applicatie tot applicatie. De berekening zelf wordt uitgevoerd met behulp van AI doordat dit verschillende baten heeft. Deze voordelen worden besproken in de volgende paragrafen.

2.2 Artificiële Intelligentie

AI verwijst naar het simuleren van menselijk intellect in machines die geprogrammeerd worden om de menselijke redenering na te bootsen. Het wordt gezien als de studie van *intelligente agents* die zijn omgeving waarnemen en acties kunnen ondernemen om de kans van het bereiken van een bepaald doel te maximaliseren[6]. Er kan een onderscheid gemaakt worden tussen zowel sterke als zwakke AI.

- **Zwakke AI:** Dit is een vorm van AI die zich bezig houdt met onderzoek in gebieden waar handswijzen mogelijk zijn die tekenen van intelligentie vertonen, maar niet volwaardig intelligent zijn. Hier worden de meeste vorderingen in voortgebracht, zoals handschriftherkenning of zoekalgoritmen.
- **Sterke AI:** Deze vorm van AI houdt zich bezig met onderzoek dat als doel heeft om software te creëren die zelfstandig kan redeneren en problemen aanpakken.

Het gebruiken van AI kan vele voordelen hebben[7][8]. Zo is het mogelijk om data beter en sneller te gebruiken dan de mens kan. Data kan gelezen en verwerkt worden in geautomatiseerde processen zonder de tussenkomst van een persoon en in een fractie van een seconde. Verder zal er ook, indien er meer beschikbare data zijn, een nog nauwkeuriger responsie gegeven worden. AI wordt als zwakke AI veel toegepast om repetitieve taken met relatief lage complexiteit over te nemen. Een belangrijk onderdeel is Machine Learning dat verder uitgelegd zal worden in volgende paragraaf.

2.3 Machine Learning

ML is een onderdeel van AI en is de studie en modellering van de verschillende leerprocessen dat gebruikt kan worden door verschillende computersystemen[9]. Deze systemen zijn hierdoor in staat om specifieke taken te voltooien zonder rechtstreekse instructies of regels mee te krijgen van de operator. Ze steunen in de plaats op onder meer patroonherkenning om de kans op het succesvol uit te voeren van taken te maximaliseren. Hiervoor wordt er een wiskundig model gebouwd dat gebruik maakt van trainingsdata. Deze mathematische modellen en *datahandling* kan op verscheidene manieren gebeuren. Hieronder worden een aantal gebruikelijke modellen besproken. Er wordt bovendien een afweging gemaakt over welk model het interessantst is voor onze toepassing.

2.3.1 Leeralgoritmes en -technieken

Om ML technieken toe te passen moet men gebruik maken van een bepaald model dat is toegepast op trainingsdata en hierdoor nieuwe data kan verwerken om voorspellingen te maken van de te verwachte resultaten. Er bestaat een hele waaier aan mogelijke modellen. In de volgende paragrafen worden een aantal opties besproken waarna er de verschillende modellen met elkaar vergeleken worden.


Artificiële Neurale Netwerken

Artificiële Neurale Netwerken (ANN) zijn een term dat gebruikt wordt om algoritmes te omschrijven. Het zijn algoritmes die in staat zijn om een bepaalde taak te leren, en zichzelf te verbeteren. In de meeste gevallen worden er amper richtlijnen of een omschrijving meegegeven. Het systeem ontdekt zelf hoe deze regels in elkaar zitten[9]. Hierbij blijft de interpretatie van de input wel nog belangrijk. Een bekend voorbeeld is het herkennen van de cijfers 0 tot 9. Hier wordt er niet aan het systeem verteld hoe de vorm van een getal er uit ziet. Het algoritme zal dit gaandeweg ontdekken, met behulp van vele voorbeelden waar het gebruik van kan maken. Met behulp van veel data kan een algoritme zichzelf verfijnen en zo nauwkeuriger bepaalde cijfers herkennen.

Structuur van Neurale Netwerken Een ANN is een verzameling van nodes die met elkaar verbonden zijn zoals neuronen in de hersens van een mens. Hierbij kan elke neuron een signaal doorgeven naar het volgende neuron waar het signaal verwerkt kan worden en weer doorgegeven kan worden. Hetzelfde principe geldt ook bij Neurale Netwerken (NN) met het verschil dat er meerdere lagen van nodes te onderscheiden zijn.


Lagen Er zijn drie soorten lagen te onderscheiden: een Input Layer, Hidden Layers en een Output Layer. Elke laag is verbonden met de volgende laag door middel van connecties tussen de verschillende nodes. In figuur 2.1 is de algemene vorm van een NN te vinden.

- **Input Layer:** De eerste laag van elke NN is de Input Layer. Deze bestaat uit een aantal inputnodes. Elke inputnode krijgt de ruwe data binnen waar er een operatie op uitgevoerd wordt en vervolgens bepaalde parameters doorgeeft aan de volgende laag. De wijze waarop data geïnterpreteerd worden, vormt een belangrijk vertrekpunt voor het NN.



Figuur 2.1: Structuur van een Neuraal Netwerk.

Afbeelding te vinden op <https://github.com/drewnoff/spark-notebook-ml-labs/tree/master/labs/DLFramework>.
Website werd geraadpleegd op 24/12/2019



Figuur 2.2: Algemene structuur van een node.

Afbeelding te vinden op <https://pathmind.com/wiki/neural-network>.

Website werd geraadpleegd op 23/12/2019.

- **Hidden Layers:** Na de inputlaag komen een aantal Hidden Layers. Het aantal Hidden Layers en de hoeveelheid nodes binnen één Hidden Layer kan variëren van applicatie tot applicatie en is sterk gerelateerd aan de complexiteit van de toepassing.
- **Output Layer:** Na de Hidden Layers is de laatste laag de Output Layer. Hier worden de laatste operaties uitgevoerd en worden de eindwaarden verkregen waar het resultaat uit afgeleid kan worden.


Nodes Lagen zijn opgebouwd uit meerdere nodes. Elke node krijgt een bepaald aantal inputs, verwerkt deze en geeft een bepaald aantal outputs. Deze inputs en outputs worden van node naar node doorgegeven via verbindingen. Elke node heeft met elke node in de volgende laag een connectie. Elke verbinding draagt een bepaald gewicht. Via dit gewicht kan men de invloed van de huidige node versterken of verzwakken in de volgende node.

Activatie functie De mathematische functie die een node gebruikt voor het verwerken van inputs naar outputs heet de activatie functie. In figuur 2.2 wordt de algemene vorm van een neuron besproken. Deze neuron heeft $m + 1$ inputs (x_0 t.e.m. x_m) en bijhorende gewichten (w_0 t.e.m. w_m). Gebruikelijk wordt $x_0 = +1$ genomen. Hierdoor blijven er maar m echte inputs over waardoor er voor een bepaalde output de functie 2.1 opgesteld kan worden. Hierbij is ϕ een van de mogelijke transferfuncties die verder besproken zal worden.

$$y = \phi \left(\sum_{j=0}^m w_j x_j \right) \quad (2.1)$$

Types activatiefuncties De transfer functie of activatiefunctie is een belangrijk onderdeel van een laag in een ANN. De activatiefunctie transformeert inputs uit een vorige laag en transformeert deze naar een output. Deze output zal voor een volgende laag weer als input gebruikt worden. Door gebruik te maken van de juiste activatiefuncties kunnen er niet-lineaire eigenschappen aan het netwerk toegevoegd worden. Hieronder zullen enkele transferfuncties besproken worden.

- **Lineaire Combinaties:** In dit geval is de output niets minder dan de gewogen som vermenigvuldigd met een constante waarbij zoals in formule 2.2 waar er nog een tweede constante wordt opgeteld.



Figuur 2.3: De Sigmoid activatiefunctie.

Afbeelding te vinden op <https://towardsdatascience.com/activation-functions-neural-networks-1cbd9f8d91d6>.

Website werd geraadpleegd op 24/12/2019.

- **Stapfunctie:** Hier wordt er gekeken naar de verkregen waarde van de gewogen som u van $m + 1$ inputs. Bedraagt deze waarde minder dan een bepaalde drempel θ , dan wordt de output gelijkgesteld aan nul, bij een hogere waarde dan weer aan 1. Dit is te zien in formule 2.3. Dit type wordt vooral gebruikt om binaire inputs te verzorgen bij de volgende laag.


$$u = \sum_{j=0}^m w_{kj} x_j \quad (2.2)$$

$$y = \begin{cases} 1 & \text{als } u \geq \theta \\ 0 & \text{als } u < \theta \end{cases} \quad (2.3)$$

$$y = \frac{1}{1 + e^{-u}} \quad (2.4)$$

- **Sigmoid:** De Sigmoid functie[10] is een mathematische functie zoals te zien is in figuur 2.4. Het heeft de karakteristieke 'S'-vorm zoals te zien is in figuur 2.3. Door deze activatiefunctie worden inputs omgezet in een waarde tussen 0 en 1 (of -1 en 1, afhankelijk van de conventie).
- **Rectifier:** De rectifier als activatiefunctie[11] is een functie die enkel het positieve deel van zijn argument doorlaat. In vergelijking 2.5 vind je de functie weer waar x de input is van de neuron. Deze is een vector aan waarden die zowel positief als negatief kunnen zijn. Deze functie is ook gekend onder de naam *rectified linear unit (ReLU)*.

$$f(x) = x^+ = \max(0, x) \quad (2.5)$$



Figuur 2.4: Algemene structuur van een beslissingsboom.

Afbeelding te vinden op <https://medium.com/machine-learning-bites/machine-learning-decision-tree-classifier-9eb67cad263e>.

Website werd geraadpleegd op 24/12/2019.

Beslissingsboom


Het gebruik van een beslissingsboom is een leermethode die met regelmaat terugkomt in de statistiek als een voorspellend model. Men maakt gebruik van observaties rond een bepaalde uitspraak. Men kwantificeert deze observaties zodat deze leiden naar een variabele outputwaarde. Indien deze waarde valt onder te verdelen in discrete klassen spreekt men over een *classificatie boom*. Neemt de gezochte variabele eerder een continue vorm aan, dan maakt men gebruik van *regressie bomen*.

Structuur van een beslissingsboom Net zoals bij de NN bestaat een beslissingsboom uit verschillende lagen en nodes. Zoals te zien is in figuur 2.4 wordt er in elke laag een onderscheid gemaakt op basis van een statement of parameter. Deze parameter kan een enkele inputwaarde zijn of een lineaire combinatie van meerdere inputwaarden.

Bij de nodes kan er onderscheid gemaakt worden tussen een gewone node en een eindnode. Bij elke gewone node wordt een bepaald statement geverifieerd en wordt er naar een node overgegaan in de volgende laag op basis van dit statement. Bij een eindnode is het niet meer mogelijk om door te gaan naar een volgende laag, maar wordt er een outputwaarde gegeven.

Support Vector Machines

Support Vector Machines (SVMs) of ook wel gekend als support vector networks is een model dat veelvuldig gebruikt wordt in classificatie en regressie-analyse. Een belangrijke toepassing van SVMs is het verdelen van objecten in twee verschillende klassen op basis van een aantal kenmerken. Het is dus onder meer een binaire classificeerder. Om aan de hand van kenmerken een onderverdeling te maken moeten deze kenmerken eerst omgezet worden in een vectorruimte. In de trainingsfase wordt er getracht een zo optimaal mogelijke scheiding tussen beide klassen te vinden. Deze optimale scheiding wordt ook wel een *hypervlak* genoemd en ligt op een zo groot mogelijke afstand tussen de dichtstbijgelegen objecten van beide klassen of support vectors. In



Figuur 2.5: Tweedimensionale Support Vector Machine.

Afbeelding te vinden op <https://subscription.packtpub.com/book/big-data-and-business-intelligence/9781788994170/5/ch05lv1sec36/support-vector-machines>.

Website werd geraadpleegd op 20/12/2019.


figuur 2.5 kan u een tweedimensionaal voorbeeld vinden. Hierin is scheidingslijn H_1 geen acceptabele scheiding omdat er objecten van de zwarte klasse fout geclassificeerd worden. H_2 is acceptabel maar is nog niet optimaal aangezien er weinig foutmarge is voor een nieuw object. H_3 is het hypervlak omdat de foutmarge tussen de twee klassen zo groot mogelijk is. Deze methode is niet alleen bruikbaar in toepassingen met een lineaire scheiding. Ook in niet-lineaire gevallen kan men een transformatie uitvoeren om toch een lineaire scheiding te bekomen. Deze hervorming wordt ook wel de *kernel trick*[12] genoemd.

Regressie Analyse

Regressie Analyse is een techniek uit de statistiek[13], die gebruikt wordt om gegevens te analyseren met een specifiek verband. Er bestaat vaak een relatie tussen een afhankelijke variabele en één (of meerdere) onafhankelijke variabelen. De meest voorkomende vorm van regressie analyse is de lineaire regressie, waar men op zoek gaat naar de functie die het dichtst aanleunt bij de data. De functie moet wel vervullen aan specifieke criteria, zo moet de functie bijvoorbeeld een bepaalde orde hebben. Regressie analyse wordt vooral gebruikt voor het voorspellen van nieuwe data of gebeurtenissen. In figuur 2.6 kan je een voorbeeld van lineaire regressie vinden.

Bayesian Netwerken

Bayesian Netwerken, ook wel probabilistische netwerken genoemd, zijn structuren waarin data op probabilistische wijze geanalyseerd kunnen worden. Dit wil zeggen dat men als output niet enkel de outputs maar ook de onzekerheid hierop krijgt. Men maakt gebruik van gerichte grafen. Hierin bestaan de knopen uit variabelen en de arcs beschrijven de conditionele afhankelijkheden tussen de verschillende knopen. Bayesian Netwerken worden vooral gebruikt om te analyseren wat de bepalende oorzaak is voor een zekere gebeurtenis.



Figuur 2.6: Voorbeeld van Lineaire Regressie.

Afbeelding te vinden op <https://en.wikipedia.org/wiki/Regression-analysis>.

Website werd geraadpleegd op 19/12/2019.

Genetische Algoritmes

Genetische Algoritmes zijn een heuristisch geïnspireerd op het principe van natuurlijke selectie en zijn een klasse binnen evolutionaire algoritmes. Dit type algoritme kan gebruikt worden om oplossingen te vinden in optimalisatie- en zoekproblemen. Door te steunen op biologische principes zoals mutatie, selectie en kruisbestuiving worden er nieuwe *chromosomen* gegenereerd die mogelijk een betere oplossing geven voor een bepaald probleem.

2.3.2 Keuze voor een Machine Learning-methode

Om de keuze voor een bepaalde ML-techniek te verantwoorden, zal dit hoofdstuk de voor- en nadelen behandelen van de voornaamste technieken die via regressie of classificatie toegepast kunnen worden[14].

Regressie

- **Neurale Netwerken:**

Voordelen: Neurale netwerken zijn de meest gebruikte toepassing in verschillende domeinen. NN kunnen uitstekend omgaan met onder meer beeld-, audio- en tekstdata en deze verwerken. Verder kan de architectuur ook nog gemakkelijk aangepast worden aan de toepassing door te variëren in het aantal lagen of nodes. Het gebruik van de hidden layers vermindert ook het hanteren van feature engineering.

Nadelen: Neurale netwerken zijn minder bruikbaar voor *general-purpose* algoritmes door de grote hoeveelheid data die er voor nodig zijn. In dat geval is het beter om voor beslissingsbomen te kiezen. Bovendien vragen ze veel computationeel vermogen voor het trainen van het netwerk en vragen veel expertise voor kleine aanpassingen zoals aan de architectuur of hyperparameters.

- **Regression Trees:**

Voordelen: Beslissingsbomen met nadruk op regressie zijn in staat om niet-lineaire relaties te leren en zijn robuust voor uitschieters in de te verwerken dataset.

Nadelen: Regression trees zijn vatbaar voor overfitting indien er te veel gebruik gemaakt wordt van branches. Bij bomen is het ook mogelijk om vertakkingen te blijven maken tot het een exacte kopie voorstelt van de trainingsdata.

- **Lineaire Regressie:**

Voordelen: Dit is een eenvoudige methode om zowel te begrijpen als uit te leggen. Daarnaast kan er een eenvoudige bescherming tegen overfitting geïmplementeerd worden.

Nadelen: Niet-lineaire relaties zijn een zwak punt voor lineaire regressie. Het is moeilijk om een correcte fitting te vinden voor een gegeven ingewikkelde relatie. Bovendien is het onvoldoende flexibel om complexe patronen op te vangen.

Classificatie

- **Neurale Netwerken:**

Voordelen: NN blijven uitstekend presteren bij het classificeren van audio-, tekst- en beeldherkenning.

Nadelen: Er is nood aan grote hoeveelheden data om het model te trainen en minder geschikt als general-purpose algoritme.

- **Classification Trees:**

Voordelen: Verrichten zeer goed werk in praktijk. Ze zijn robuust voor uitschieters, schaalbaar voor meerdere klassen en kunnen niet-lineaire grenzen op natuurlijke wijze modelleren dankzij de hiërarchische structuur.

Nadelen: Classification trees zijn vatbaar voor overfitting indien er te veel gebruik gemaakt wordt van branches. Bomen hebben vaak de neiging om branches aan te maken tot het een exacte kopie voorstelt van de trainingsdata.

- **Support Vector Machines:**

Voordelen: SVMs zijn in staat om niet-lineaire beslissingsgrenzen te modelleren en hebben een sterke robuustheid tegen overfitting, vooral in hogere dimensionale vectorruimtes.

Nadelen: SVMs zijn heel erg geheugen intensief. Ze vragen ook meer expertise in het afstemmen door het grote aanbod in mogelijke kernels. SVMs hebben de eigenschap om minder effectief te zijn bij het schalen naar grotere datasets.

- **Geregulariseerde Regressie:**

Voordelen: Outputs hebben een gemakkelijk leesbare probabilistische interpretatie. Ook kan er bescherming tegen overfitting geïmplementeerd worden en kunnen modellen eenvoudig geüpdatet worden.

Nadelen: Niet-lineaire relaties zijn een zwak punt voor lineaire regressie. Het is moeilijk om een correcte fitting te vinden voor een gegeven ingewikkelde relatie. Bovendien is het onvoldoende flexibel om complexe patronen op te vangen.

Besluit

Na een afweging gedaan te hebben van de voor- en nadelen van de voornaamste kandidaten bij zowel regressie als classificatie toepassingen zal in het kader van deze thesis voor NN gekozen worden. Er wordt vooral gesteund op het feit dat NN uitstekend werk levert in beide klassen in het analyseren van data. Bovendien zijn de voornaamste nadelen minder van toepassing in het kader waarin NN toegepast zal worden. Het is vooral van belang hoe de netwerken in de executiefase presteren. Het trainen van de verschillende netwerken met grote hoeveelheden data kan op aparte systemen gebeuren. De trainingsfase is dus minder van belang voor het doel van deze thesis. Bovendien is het niet nodig om een breed general-purpose netwerk te voorzien.

Een mogelijk alternatief voor NN is het gebruiken van Regressie Analyse. De bepalende factor hiervoor is dat het karakter van de verscheidene applicaties vaak uit lineaire relaties bestaat.

2.3.3 Leertechnieken

Er zijn verschillende mogelijkheden om een neurale netwerk te laten leren. De drie belangrijkste methodes om een mathematische functie te verkrijgen worden hieronder opgesomd[3].

Supervised Learning


Deze techniek maakt gebruik van gepaarde datasets van inputobjecten en de te verwachten outputobjecten. Het doel is om een mathematische functie te creëren waarbij de gegenereerde outputs zo nauw mogelijk overeenkomen met de gelabelde outputs uit de datasets. Men optimaliseert deze mathematische functie door iteratief te trainen. De bijgeschaafde functie kan dan ook gebruikt worden voor nieuwe datasets zonder gelabelde output. Hierbij zal hij zelf outputwaarden genereren. Een toepassing van Supervised Learning is bijvoorbeeld het detecteren van spam met een trainingset van al gelabelde e-mails.

Unsupervised Learning

Unsupervised learning is een techniek die gebruik maakt van Hebbian Learning om onbekende patronen te herkennen in datasets. De twee meest gebruikte methodes onder Unsupervised Learning zijn principal component analysis en cluster analysis. Principal component analysis maakt gebruik van orthogonale transformaties om een set van mogelijke afhankelijke variabelen om te zetten in een set van lineaire onafhankelijke variabelen. In cluster analyse wordt er getracht om een groep objecten te identificeren en te verdelen in een cluster van gelijkaardige objecten. Een belangrijke toepassing van Unsupervised Learning is het clusteren van gelijkaardige documenten op basis van de inhoud van de tekst.

Reinforcement Learning

Deze leertechniek heeft betrekking tot hoe agents acties moeten ondernemen in een omgeving om een bepaald attribuut te maximaliseren. Het onderscheidt zich van Supervised en Unsupervised Learning door de onafhankelijkheid van gelabelde outputdatasets. De techniek heeft als doel om een evenwicht te vinden tussen exploratie van ongekend gebied en exploitatie van de huidige kennis. In figuur 2.7 kan je een eenvoudige routine vinden van Reinforcement Learning-algoritme. Hierbij maakt een agent een bepaalde actie gebaseerd op de staat waar hij in is. Deze actie heeft in een omgeving een zekere invloed die door een Interpreter beoordeeld wordt en een score toekent. De agent kan deze verandering daarna gebruiken om zichzelf te verbeteren en zijn acties aanpassen. Een van de vele mogelijke toepassingen van Reinforcement Learning is het aanleren van schaken door enkel mee te geven of het algoritme gewonnen of verloren heeft.



Figuur 2.7: Routine bij Reinforcement Learning.

Afbeelding te vinden op <http://webindream.com/reinforcement-learning/>.

Website werd geraadpleegd op 23/12/2019.

2.4 Evolutie Single Board Computers


Een SBC is een volledige computer gemaakt op 1 enkele printplaat. Het bevat onderdelen zoals een microprocessor, geheugen, inputs en outputs. De eerste SBC werd ontwikkeld als een voorstel-hulpmiddel bij educatieve doelstellingen of het gebruik als een embedded computer controller. Tegenwoordig zijn ook vele (draagbare) computers geïntegreerd op één printplaat. Het grote verschil met (draagbare) computers is dat er geen nood is aan expansion slots zoals bijvoorbeeld voor RAM-geheugen of een Graphics Processing Unit (GPU).

2.4.1 Geschiedenis

De eerste echte SBC was de zogenaamde "dyna-micro" uit figuur 2.8 die later de naam "MMD-1" (Mini-Micro Designer 1) kreeg[15]. Dit toestel werd uitgegeven in 1976 en werd populair doordat het werd gepresenteerd in het destijds 'BugBook'. Een andere vroege SBC was de KIM-1 (Keyboard Input Monitor 1) uit hetzelfde jaar. Beide machines werden voor ingenieurs geproduceerd en ontworpen maar vonden een breed publiek onder de hobbyisten waar het heel populair werd. Later kwamen nog andere namen zoals de Ferguson Big Board en de Nascom.

Naarmate de markt voor desktops en PC's groeide, nam de belangstelling voor SBC in computers meer en meer af. De focus van de markt werd verlegd naar een moederbord met de belangrijkste componenten en dochterborden voor periferiecomponenten zoals seriële poorten. De voornaamste reden hiervoor was dat de componenten groot waren. Alle onderdelen op dezelfde printplaat zou zorgen voor een onpraktisch ontwerp met grote afmetingen. Deze beweging was echter tijdelijk en naarmate de vorderende technologie kleinere componenten kon leveren, werden onderdelen terug naar het mainframe verschoven. Tegenwoordig kunnen de meeste moederborden terug als SBC beschouwd worden.

In het jaar 2004 werd er in Italië een nieuwe microcontroller uitgebracht onder de naam "Arduino". Dit ontwerp had, naast het voordeel van compact en goedkoop te zijn, ook nog eenvoudigheid mee. Door de eenvoud werd het Arduino-platform snel populair onder techneuten van alle soorten. Twee jaar later bracht de Universiteit van Cambridge een nieuwe goedkope SBC uit. De bekende Raspberry Pi werd gelanceerd voor de prijs van \$35. Het hoofddoel van dit project was een nieuw



Figuur 2.8: Eerste SBC: MMD-1.

Afbeelding te vinden op <https://nl.wikipedia.org/wiki/Singleboardcomputer>.
Website werd geraadpleegd op 23/12/2019.

leermiddel om te programmeren maar werd door het grote aantal applicaties ook zeer populair.

De laatste jaren kende een grote explosie aan nieuwe SBCs. Een hele reeks nieuwe namen verschenen. Banana Pi, Beaglebone, Intel Galileo, Google Coral Dev en Asus Tinker Board zijn maar enkele van de vele voorbeelden. Deze toestellen hebben vaak een processor gebaseerd op de x86- of ARM-series en maken gebruik van een Linux besturingssysteem zoals Debian.

2.5 Assortiment aan 'off the shelf' toestellen

In deze sectie wordt er een kort overzicht gegeven van de te gebruiken SBCs binnen deze thesis. Er werd gekozen om met vijf verschillende toestellen te werken die verschillen in verscheidene aspecten. Zo zijn er zowel goedkope als kostelijkere apparaten, populaire boards als minder gekende SBCs. Er zijn toestellen met hele geavanceerde processoren die specifiek voor ML zijn ontworpen, maar ook processoren die ontwikkeld zijn voor meer algemenere toepassingen. De specificaties van de verscheidene toestellen worden ook meegegeven.

2.5.1 Beaglebone AI

BeagleBone Ai (BB AI) is een SBC dat verder bouwt op de succesvolle BeagleBoard-series[16]. Het is een open source project met een op Linux gebaseerd aanpak. De BB AI probeert het gat tussen kleinere SBC en krachtigere industriële computers te overbruggen. Met dank aan de krachtige Texas Instruments AM5729 CPU kunnen ontwikkelaars de krachtige System On Chip (SoC) gebruiken van een hele brede waaier aan toepassingen op het AI terrein. De BB AI maakt het makkelijk om dat terrein te ontdekken en verkennen. Door gebruik te maken van onder andere embedded-vision-engine (EVE) cores die steunen op een geoptimaliseerde TIDL machine learning OpenCL API met gebruiksklare hulpmiddelen kan je terecht in alledaagse automatisatie in industriële, commerciële en thuisapplicaties.

Specificaties

- **GPU:** Niet van toepassing
- **CPU:** Texas Instruments AM5729
- **Memory:** 16 GB on-board eMMC flash
- **Storage:** 1GB RAM + micro SD-slot
- **Power:** 5 Watt
- **Prijs:** \$139.37

2.5.2 Coral Dev Board

De Coral Dev Board is een development board gemaakt door het Amerikaanse technologiebedrijf Google[17]. Het board is ontworpen om het ontwikkelen van on-device ML producten te vergemakkelijken. Hiervoor heeft het een aantal belangrijke voordelen gekregen door zijn designers. Het is vooral de aangepaste Tensor Processing Unit (TPU) AI chip die hier opvalt. De TPU is een Application Specific Integrated Circuit (ASIC) speciaal ontworpen voor NN ML, en is in staat om video in hoge resolutie te analyseren aan 30 frames per second. Deze System-on-Module (SoM) is geoptimaliseerd om Tensorflow Lite te kunnen draaien aan meerdere tera operations per second (TOPS).

Specificaties

- **GPU:** Integrated GC7000 Lite Graphics
- **CPU:** NXP i.MX 8M SOC (quad Cortex-A53, Cortex-M4F) + coprocessor Google Edge TPU
- **Memory:** 8 GB on-board eMMC flash
- **Storage:** 1GB RAM LPDDR4 + micro SD-slot
- **Power:** 0.5 watts for each TOPS - 2 Watt
- **Prijs:** \$149.99

2.5.3 Nvidia Jetson Nano

De Jetson Nano is een populair bord uit de Jetson Series van Nvidia[18]. Het is een kleine maar krachtige computer ontwikkeld voor embedded applicaties en low-power AI-Internet-Of-Things (IOT). Deze SBC wordt ondersteund door meerdere bibliotheken in sectoren zoals deep learning, computer vision, beeld en multimedia. De hardware bevat zowel een GPU als een Central Processing Unit (CPU). De GPU bestaat uit een krachtige Maxwell architectuur die beeld kan decoderen aan 500 MP/sec. De CPU is van het type Cortex-A57 met 4 kernen.

Specificaties

- **GPU:** 128-core Maxwell met 128 CUDA-cores
- **CPU:** Quad-core ARM A57 @ 1.43 GHz
- **Memory:** 4 GB 64-bit LPDDR4 25.6 GB/s
- **Storage:** micro SD-slot
- **Power:** 5 W
- **Prijs:** \$99

2.5.4 Nvidia Jetson TX2

De TX2, uit de zelfde Jetsonserie, is de high end versie van de hiervoor besproken Nano[19]. Het is het snelste en meest power-efficiëntst van de embedded AI toestellen die gebruikt zal worden in deze thesis. De TX2 verbruikt een 7.5 Watt en brengt het zware AI-rekenwerk naar de edge. Zijn bekwame GPU met 256 CUDA kernen en een duo CPU zijn in staat om de meest geavanceerde Machine Leertechneken uit te voeren. De grote geheugenvoorzieningen zorgen bovendien dat de datasetgrootte geen beperkende factor meer kan spelen. Verder wordt er nog gezorgd voor een grote ondersteuning via een grote variatie aan hardware interfaces. Hierdoor wordt het integreren van producten aanzienlijk makkelijker.

Specificaties

- **GPU:** 256-core NVIDIA Pascal GPU architecture with 256 NVIDIA CUDA cores
- **CPU:** Dual-Core NVIDIA Denver 2 64-Bit & CPU Quad-Core ARM Cortex-A57 MPCore
- **Memory:** 8GB 128-bit LPDDR4 Memory 1866 MHz - 59.7 GB/s
- **Storage:** 32GB eMMC 5.1
- **Power:** 7,5 - 15 W
- **Prijs:** \$399

2.5.5 Raspberry Pi

De laatste SBC die hier besproken is de Raspberry Pi 4[20]. Dit is een heel goedkoop en eenvoudig device. Het komt uit de heel gekende Raspberry-reeks zoals al besproken in paragraaf 2.4.1. Ondanks de enorm lage prijs heeft de vierde editie nog mooie specificaties. Het heeft een behoorlijke Cortex Quad core-CPU met degelijk geheugen die uitgebreid wordt door een SD-kaart.

Specificaties

- **CPU:** Broadcom BCM2711, Quad core Cortex-A72 (ARM v8) 64-bit SoC @ 1.5GHz
- **Memory:** 1GB, 2GB or 4GB LPDDR4-3200 SDRAM
- **Storage:** micro SD-kaart
- **Power:** 2,8 - 5,2 W
- **Prijs:** \$35

2.6 Benchmarking van Machine Learning algoritmes

Om betekenisvolle resultaten te verkrijgen is het nodig om een goed bruikbare en representatieve benchmark op te stellen. Een benchmark is een onderzoek waarbij de prestaties van programma's met elkaar vergeleken worden. Dit komt tot stand als elk programma op identieke wijze wordt onderzocht. Door de prestaties van programma's met elkaar te vergelijken is het mogelijk de performantie van de verscheidene SBC in kaart te brengen. Hoe de benchmark exact in elkaar zit is gebonden aan de kwaliteitscriteria die onderzocht worden. Om ervoor te zorgen dat de benchmark onafhankelijk is van zowel het specifiek veld als toepassing, is het nodig dat er aan een aantal karakteristieken wordt voldaan[21].

- **Vergelijkbaarheid:** Benchmarks moeten zodanig opgesteld zijn, dat het evident is wat ze vergelijken en de conclusie ondubbelzinnig is.
- **Herhaalbaarheid:** Bij het herhalen van de test onder gelijkaardige omstandigheden moeten gelijkaardige resultaten gehaald worden.
- **Goed gedefinieerde methodologie:** De werkwijze, methode en aannames moeten voldoende gedocumenteerd en gestaafd worden.
- **Configureerbaar:** Benchmarks moeten beschikken over parameters die aangepast kunnen worden naar het specifieke probleem dat wordt behandeld.

2.6.1 Bestaande benchmarks


De ontwikkelaars van de Jetson Nano vermelden op de Nvidia-website[22] verschillende Deep Learning Inference Benchmarks (DLIB) waarbij de auteur verscheidene op voorhand getrainde Deep Learning (DL) modellen toepassen op het Nano bord. Deze modellen zijn gebaseerd op een brede waaier aan populaire ML frameworks zoals Tensorflow, Caffe, PyTorch en Keras. Bovendien zijn de applicaties ook gespreid over meerdere toepassingen zoals beeldherkenning, objectdetectie, positiebepaling en anderen. De modellen en resultaten zijn te vinden in figuur 2.9.

Ook voor de Jetson TX2 bestaat er een benchmark zoals voorgesteld in [23]. Het gaat over een general-purpose benchmark die een aantal parameters controleert. Het gaat over variabelen zoals Frames per Second (FPS), *inference time*, GPU temperatuur en geheugen verbruik. Met *inference time* wordt de tijd bedoeld om een berekening te doen in GPU en CPU m.a.w. de latency veroorzaakt door de SBC. Deze gegevens worden uit de data gehaald door middel van verschillende DL modellen toe te passen op Convolutional Neural Networks (CNN). Deze modellen passen ze toe op twee verschillende datasets: Microsoft COCO dataset voor objectdetectie, een foto bank met een grote verscheidenheid aan categorieën, en de KITTI Stereo Vision databank. De KITTI-databank bestaat uit 400 foto's specifiek bedoeld als benchmark fotoset.

Er bestaan ook meer algemenere benchmarks om vergelijkingen tussen computersystemen te maken. Zo bestaat er ook de LINPACK benchmarks[24]. Dit is een programma waar de snelheid gemeten kan worden waarmee een computer in staat is om een n bij n matrix van lineaire vergelijkingen op te lossen. Ondanks dat het een veelgebruikte benchmark is, zijn er wel nog bedenkingen over de werkwijze. Zo bestaat de kerntaak maar uit een enkele computationele taak die onmogelijk de algemene performantie van een systeem kan weergeven. Desondanks geeft de LINPACK benchmark een goed karakteristiek beeld van computersystemen. De meest bekende

Deep Learning Inference Performance

Jetson Nano (FP16, batch size 1)



Figuur 2.9: Modellen en resultaten van de benchmark op de Jetson Nano.

Afbeelding te vinden op <https://devblogs.nvidia.com/jetson-nano-ai-computing/>.

Website werd geraadpleegd op 17/02/2020.

toepassing waar LINPACK in toegepast wordt is de ranking van de beste 500 supercomputers ter wereld[25]

Hoofdstuk 3

Data verwerving

In dit hoofdstuk wordt de verwerving van de data toegelicht. Er wordt eerst enkele belangrijke specificaties van de gebruikte toestellen besproken. Vervolgens worden de gehanteerde programma's doorgenomen op vlak van gebruikte data en type NN. Het hoofdprogramma wordt in de Python-programmeertaal geschreven. Deze taal werd gekozen door de veelvuldige toepassingsmogelijkheden binnen ML. Tot slot wordt de dataverwerving van de benchmark zelf geïllustreerd en besproken hoe de data opgeslagen wordt.

3.1 Verkennen van software

3.2 Verkennen edge-devices


3.3 Structuur programma

In deze sectie wordt de structuur van het hoofdprogramma besproken. De belangrijkste onderdelen van de programma's worden toegelicht. Zo wordt er weergegeven hoe de verschillende NN-modellen opgebouwd zijn en op welke data ze worden toegepast voor zowel het trainen als het uitvoeren. De benchmark bevat in totaal 10 verschillende subprogramma's. Elk van deze is een neurale netwerk met een zekere complexiteit bedoeld voor weide variatie aan applicaties. Van de 10 subprogramma's kunnen er zes van gecategoriseerd worden als regressie en vier als classificatie. Voor elk subprogramma wordt er uitgelegd hoe het model wordt opgesteld, hoe het getraind wordt en hoe het uiteindelijk uitgevoerd wordt. Voor de benchmark is vooral het uitvoeren van de modellen van belang. Het opstellen en trainen van een NN is een eenmalige taak en hoeft bijgevolg niet op edge-devices gebeuren.

3.3.1 Regressie subprogramma's

Voor de regressie subprogramma's werd er gekozen om gebruik te maken van pyrenn¹. Dit is een toolbox voor zowel Python als Matlab. Deze laat op een heel eenvoudige manier NN trainen en uitvoeren. De pyrenn-toolbox heeft 2 dependencies of afhankelijkheden in Python. Deze zijn de

¹ Meer info over pyrenn is te vinden op <https://pyrenn.readthedocs.io/en/latest/index.html>



Figuur 3.1: Praktische betekenis van het compair-subprogramma.

Afbeelding te vinden op <https://pyrenn.readthedocs.io/en/latest/examples.html>

Website werd geraadpleegd op 10/04/2020.

subprogramma	index	P1	P2	P3	Y1	Y2
compair	464	0	1	0.8	7	8.4
friction	14	-3			-0,29148	
narendra4	80	-0,54404			-0,45803	
pt2	208	-7,96923			-0,44761	

Tabel 3.1: Voorbeelden van de gebruikte data voor regressiemodellen.

gekende pandas en numpy packages. De volgende subprogramma's worden opgesteld met behulp van de pyrenn-voorbeelden.

Programma 1: compair

Het eerste subprogramma is een *compressed air storage system* of een samengedrukte lucht opslagsysteem. Het systeem met drie verschillende inputs en 2 gewenste outputs. De praktische werking wordt verduidelijkt in figuur 3.1 maar wordt in deze thesis verder niet op in gegaan. Hier wordt er een Recurrent Neural Network (RNN) toegepast. Dit is een regulier NN waar er een terugkoppeling bestaat tussen een node naar een vorige laag toe.

Aanmaken en trainen model Voor dit subprogramma werd er gewerkt met een dataset voorzien door Pyrenn zelf. Deze dataset levert in totaal 960 data inzendingen voor de inputs en outputs. Hiervan zijn er 480 inzendingen voorzien voor trainen en 480 voor testen van het model. In tabel 3.1 kan u een voorbeeld vinden van één dataliijn. Hierbij is de inputdata P een lijst van drie features $P1$, $P2$ en $P3$. Analooft geldt dat de te verwachten outputdata Y een lijst voorstelt met twee features $Y1$ en $Y2$. Het NN wordt hier gedefinieerd door vier lagen. Een inputlaag, twee verborgen lagen en een outputlaag. Het aantal nodes voor de input- en outputlaag zijn gekend: drie en twee nodes respectievelijk. Voor de twee hidden layers werd er gekozen om vijf nodes elk te implementeren. Het model kan gecreëerd worden met het commando `CreateNN()` zoals te zien is in listing 3.1. De variabele `net` bevat de vorm van het model. In het commando kunnen parameters toegevoegd worden. Zo wordt in een lijst de grootte en de lengte van de laag meegegeven. De parameters `dIn`, `dIntern` en `dOut` kunnen gebruikt worden om wederkerende verbindingen te maken. Zo wordt in dit subprogramma `dOut` op de waarde 1 gezet om van de outputlaag een verbinding met

een vertraging van 1 tijdsperiode naar de vorige laag aanbrengen. Vervolgens wordt het model getraind met de data met het commando `train_LM()`. Hierbij worden parameters zoals `k_max` en `E_stop` toegepast om respectievelijk aan te duiden voor hoeveel iteraties er maximaal getraind mag worden en de minimale fout dat bereikt mag worden. Tot slot word het model ook opgeslagen in een Comma Separated Value (CSV)-bestand via het commando `saveNN()`. Het uitvoeren van het model kan dan op een apart device gebeuren.

```
# Create and train NN
net = pyrenn.CreateNN([3, 5, 5, 2], dIn=[0], dIntern=[], dOut=[1])
net = pyrenn.train_LM(P, Y, net, verbose=True, k_max=500, E_stop=1e-5)
# Save outputs to certain file
prn.saveNN(net, "./models/compair.csv")
```

Listing 3.1: Creëren en trainen van pyrenn-model.

Uitvoeren model Via het commando `loadNN()` kan het model van uit een bestand terug in een variabele worden opgeslagen. Het uitvoeren van het model zelf op testdata kan gebeuren via de instructie `NNOut()`. Het resultaat hiervan wordt in de variabele `y` opgeslagen zoals in listing 3.2. In vele toepassingen is het wenselijk dat variabele `y` zo nauw mogelijk aansluit met de echte waarden `Y`. In deze thesis is de accuraatheid van het model echter niet van belang. De parameters die hier onderzocht worden zijn onafhankelijk van de accuraatheid van het model. Deze wordt dus ook niet berekend en verder gebruikt.

```
# Load saved NN from file
net = prn.loadNN("./models/compair.csv")
# Calculate outputs of the trained NN for train and test data
y = prn>NNOut(P, net)
```

Listing 3.2: uitvoeren van pyrenn-model.

Programma 2: friction

Het friction-subprogramma is een voorbeeld dat een fysische grootheid berekend. Het gaat hier over de wrijvingskracht F in functie van de snelheid v . Deze grootheden voldoen aan formule 3.1.

$$F = \frac{\tanh(25 \cdot v) - \tanh(v)}{2} + \frac{\tanh(v)}{5} + 0.03 \cdot v \quad (3.1)$$

Uit deze formule kan er afgeleid worden dat we met statisch systeem met één input, v , en één output, F werken. Voor analogie met de andere pyrenn-subprogramma's worden deze respectievelijk P en Y genoemd. De pyrenn-dataset waar we hier van gebruik maken bestaat 41 datapunten voor het trainen en 201 datapunten voor het testen van het model. Een voorbeeld van een datapunt kan in tabel 3.1 gevonden worden. Het model dat hier gebruikt wordt is een regulier NN en bestaat uit vier lagen. De input- en outputlaag bestaan uit één node. De twee hidden layers bestaan hier elk uit 3 nodes. Zowel het creëren en trainen als het uitvoeren van het model gebeuren aan analoge wijze als in listing 3.1 en 3.2.

Programma 3: narendra4

Narendra4 is een programma dat de narendra4-functie[26] beschrijft. Dit is een voorbeeld van een dynamisch systeem met slechts één output en één input met vertraging en wordt beschreven in vergelijking 3.2. Een datapunt kan gevonden worden in tabel 3.1. Het model zal ook een RNN vormen. Hier zullen er grotere terugkoppelingen aanwezig zijn. Om een output y_{k+1} te berekenen moeten de twee vorige inputs p_{k-1} en p_k ook bekend zijn. Er zal dus een vertraging van twee tijdsperiodes aanwezig zijn voor de inputnode. Dit vertaalt zich in de inputvariabele dIn uit listing 3.4 die nu gelijk is aan de waarde $[1,2]$. Op analoge wijze zijn er drie tijdsperiodes vertraging aanwezig voor de outputnode: $dOut$ is nu gelijk aan de waarde $[1,2,3]$. De twee tussenliggende verborgen lagen, die elk uit drie nodes bestaan, ondervinden zelf geen vertragingen. Het uitvoeren van het RNN gebeurt weer op analoge wijze als in listing 3.2.

$$y_{k+1} = \frac{y_k \cdot y_{k-1} \cdot y_{k-2} \cdot p_{k-1} \cdot (y_{k-2} - 1) + p_k}{1 + (y_{k-1})^2 + (y_{k-2})^2} \quad (3.2)$$

```
# Create and train NN
net = pyrenn.CreateNN([1, 3, 3, 1], dIn=[1, 2], dIntern=[], dOut=[1, 2, 3])
net = pyrenn.train_LM(P, Y, net, verbose=True, k_max=200, E_stop=1e-3)
# Save outputs to certain file
prn.saveNN(net, "./models/narendra4.csv")
```

Listing 3.3: Creëren en trainen van pyrenn-model voor narendra4.

Programma 4: pt2

Het subprogramma pt2 is een programma dat een dynamisch systeem met één input en één output beschrijft. Het te gebruiken systeem hier is een tweede order transfer functie zoals in vergelijking 3.3 is opgetekend. De gebruikte pyrenn-dataset is ook hier een set met één input feature, P , en één output feature, Y . Ook van deze set is een datapunt opgenomen in tabel 3.1. In totaal zijn er 1000 datapunten beschikbaar, waarvan 500 voor het trainen en 500 voor het testen. Voor het creëren van dit model is er voor gekozen om naast de input- en outputlaag, twee hidden layers te implementeren met elk twee nodes. Voor deze hidden layers wordt er een vertraging van 1 tijdsperiode voorzien. Voor de uitgang wordt er een terugkoppeling van één en twee tijdsperiodes voorzien. De waardes voor $dIntern$ en $dOut$ zijn dus respectievelijk $[1]$ en $[1,2]$ bij het aanmaken van dit model. Zowel trainen er runnen gebeuren analoog aan listing 3.1 en 3.2.

$$G(s) = \frac{Y(s)}{U(s)} = \frac{10}{0.1 \cdot s^2 + s + 100} \quad (3.3)$$

Programma 5: P0Y0-narendra4

Het P0Y0-narendra4-subprogramma is een programma dat gebruik maakt van al gekende data bij het uitvoeren van een getraind netwerk. Bij een RNN is dit een interessant gegeven voor het model. Het kan meteen de vertraagde inputs and outputs een waarde geven in plaats van deze te initialiseren op nul. Dit bevordert de accuraatheid bij de start van het uitvoeren. Dit programma wordt toegepast op de narendra4-dataset. Het wordt dus op dezelfde wijze gecreëerd en getraind.

Het verschil ligt bij het uitvoeren van het model. Hierbij worden er aan het *NNOut()* commando drie willekeurig opeenvolgende datapunten in lijstvorm voor zowel de input als output.

Programma 6: gradient

Dit subprogramma berekent de gradiënt-vector van de fout-marge van een NN. Deze berekening is mogelijk met twee verschillende algoritmen gebeuren: Real Time Recurrent Learning (RTRL) en Back Propagation Trough Time (BPTT). In deze thesis wordt er gebruik gemaakt van het RTRL-algoritme. Deze werd in de documentatie beschrijven als een snellere oplossing bij het uitvoeren van het model. Dit subprogramma wordt toegepast op de pt2-dataset. Het model wordt bijgevolg op dezelfde wijze gedeclareerd als het pt2-subprogramma. De train- en run-commando's zijn te vinden in listing .

```
# Create and train NN
net = prn.CreateNN([1, 2, 2, 1], dIn=[0], dIntern=[1], dOut=[1, 2])
data, net = prn.prepare_data(P, Y, net)
# Run NN
J, E, e = prn.RTRL(net, data)
```

Listing 3.4: Creëren en trainen van pyrenn-model voor narendra4.

3.3.2 Classificatie subprogramma's

Programma 7: FashionMNIST

Het FashionMNIST-subprogramma is samen met NumberMNIST een van de klassiekers voor starters die kennis met ML en NN willen maken. Bovendien worden beide programma's ook regelmatig in andere benchmarks gebruikt wat vergelijkbaarheid bevordert. Voor deze redenen zullen we beiden ook in de benchmark opnemen. FashionMNIST is een NN dat foto's van kledij-stukken probeert te classificeren volgens tien mogelijke labels.

Aanmaken en trainen model Voor we het model beschrijven wordt er eerst de te gebruiken data verkent. De dataset² van foto's en labels die voor het trainen gebruikt wordt, bestaat uit 60.000 instanties. Elke instantie uit de foto-dataset omvat een foto van 28 bij 28 pixels. Elke pixel bestaat hier uit 1 waarde en is dus geen RGB-pixel met drie waardes. In figuur 3.2 zijn er enkele voorbeelden van instanties terug te vinden. Voor het model opgesteld kan worden moet de data eerst nog verwerkt worden naar een schaal die voor de compiler van het model beter te verwerken is. De waarde van 1 pixel varieert tussen nul en 255. De waarden worden door het maximum, 255, gedeeld zodat deze tussen 0 en 1 komen te liggen. Vervolgens kan het model gedeclareerd worden. In listing 3.5 wordt de declaratie, compilatie en het trainen van het model getoond. Het model bestaat uit drie lagen. Aan de inputlaag wordt de verwerkte data ingegeven in matrixvorm. Vervolgens worden de 784 waarden omgezet via een hidden layer met 128 nodes en een relu-activatiefunctie naar de output. In de outputlaag wordt er de *softmax*-activatiefunctie toegepast. Deze functie zorgt voor probabilistische uitkomst voor elke outputnode. Elke node zal hierdoor een waarde krijgen die overeenstemt met de kans dat het model de input acht overeen te komen met een bepaald label. De som van de waarden in alle outputnodes moet gelijk zijn aan 1. Na

²Datasets te vinden op: <https://www.kaggle.com/zalando-research/fashionmnist>, website geraadpleegd op 13/04/20.



Figuur 3.2: Enkele voorbeelden uit de FashionMNIST-dataset.

Afbeelding te vinden op <https://becominghuman.ai/how-to-create-a-clothing-classifier-fashion-mnist-program-on-google-colab-99f620c24fcd>

Website werd geraadpleegd op 13/04/2020.

het declareren, wordt het model gecompileerd. In het *compile()*-commando worden verschillende parameters zoals optimizer en loss-functie meegedeeld aan de compiler. Deze bepalen de wijze waarop het model gecompileerd wordt. Tot slot wordt met het *fit()*-commando het trainen gestart. Hier worden de verwerkte inputdata en bijhorende labels aan toegevoegd.

```
# Building the model
model = tf.keras.Sequential([
    keras.layers.Flatten(input_shape=(28, 28)),
    keras.layers.Dense(128, activation="relu"),
    # the probability for each given class (total =1)
    keras.layers.Dense(10, activation="softmax")])

# Compile the model
model.compile(optimizer="adam",
              loss="sparse_categorical_crossentropy",
              metrics=["accuracy"])

# training the model
model.fit(train_images, train_labels, epochs=5)
```

Listing 3.5: Creëren en trainen van sequentieel model voor FashionMNIST.

Uitvoeren model

Programma 8: NumberMNIST**Programma 9: catsVSdogs****Programma 10: Image Recognition****3.3.3 Conversie naar TFLite**

Doordat er in deze thesis gebruik gemaakt wordt van devices die met Tensorflow Lite (TFLite) werken worden de modellen omgezet naar een TFLite-model. Dit gebeurt door een convertor-object te creëren van het bestaande keras-model. Op deze convertor worden optimalisatietechnieken uitgevoerd waarna het model wordt omgezet naar een TFLite-equivalent model. Dit model wordt vervolgens met het commando *write()* uitgeschreven naar het gewenste bestand. Dit nieuwe model kan vervolgens opgeroepen worden voor uitvoering op gewenste momenten. In listing 3.6 kan de gebruikte code terug gevonden worden.

```
# Convert the model
converter = tf.lite.TFLiteConverter.from_keras_model(model)
converter.optimizations = [tf.lite.Optimize.DEFAULT]
tflite_quant_model = converter.convert()
# Saving tflite model
open(path_model + "fashionMNISTmodel.tflite",
     "wb").write(tflite_quant_model)
```

Listing 3.6: Converteren naar een TFLite-model.

3.4 Uitvoeren metingen**3.5 Opslaan van data**

Hoofdstuk 4

Data verwerking

Hoofdstuk 5

Resultaten

Hoofdstuk 6

Conclusie

Bibliografie

- [1] M. R. Minar and J. Naher, "Recent advances in deep learning: An overview," 02 2018.
- [2] J. Bloem, M. Van Doorn, S. Duivestein, D. Excoffier, R. Maas, and E. Van Ommeren, "The fourth industrial revolution," *Things Tighten*, vol. 8, 2014.
- [3] S. J. Russell and P. Norvig, *Artificial intelligence: a modern approach*. Malaysia; Pearson Education Limited,, 2016.
- [4] L. Barreto, A. Amaral, and T. Pereira, "Industry 4.0 implications in logistics: an overview," *Procedia Manufacturing*, vol. 13, pp. 1245–1252, 2017.
- [5] H. Li, K. Ota, and M. Dong, "Learning iot in edge: Deep learning for the internet of things with edge computing," *IEEE Network*, vol. 32, no. 1, pp. 96–101, Jan 2018.
- [6] D. I. Poole, R. G. Goebel, and A. K. Mackworth, *Computational intelligence*. Oxford University Press New York, 1998.
- [7] <https://www.frankwatching.com/archive/2017/02/06/artificial-intelligence-6-redenen-waarom-je-juist-nu-moet-> accessed on 27.1.2020.
- [8] https://www.sas.com/en_us/insights/analytics/what-is-artificial-intelligence.html, accessed on 27.1.2020.
- [9] J. G. Carbonell, R. S. Michalski, and T. M. Mitchell, "An overview of machine learning," in *Machine learning*. Springer, 1983, pp. 3–23.
- [10] J. Han and C. Moraga, "The influence of the sigmoid function parameters on the speed of backpropagation learning," in *International Workshop on Artificial Neural Networks*. Springer, 1995, pp. 195–201.
- [11] V. Nair and G. E. Hinton, "Rectified linear units improve restricted boltzmann machines," in *Proceedings of the 27th international conference on machine learning (ICML-10)*, 2010, pp. 807–814.
- [12] F. Sun, "Kernel coherence encoders," 2018.
- [13] I. Sieben and L. Linssen, "Logistische regressie analyse: een handleiding," *Geraadpleegd via www.ru.nl/publish/pages/525898/logistischeregressie.pdf*, 2009.
- [14] <https://elitedatascience.com/machine-learning-algorithms>, accessed on 21.12.2019.
- [15] <https://nl.wikipedia.org/wiki/Singleboardcomputer>, accessed on 23.12.2019.

- [16] <https://beagleboard.org/ai>, accessed on 23.12.2019.
- [17] <https://venturebeat.com/2019/10/22/googles-coral-ai-edge-hardware-launches-out-of-beta/>, accessed on 23.12.2019.
- [18] <https://developer.nvidia.com/embedded/jetson-nano>, accessed on 23.12.2019.
- [19] <https://developer.nvidia.com/embedded/jetson-tx2>, accessed on 23.12.2019.
- [20] <https://www.raspberrypi.org/products/raspberry-pi-4-model-b/>, accessed on 23.12.2019.
- [21] L. A. Libutti, F. D. Igual, L. Pinuel, L. De Giusti, and M. Naiouf, "Benchmarking performance and power of usb accelerators for inference with mlperf."
- [22] <https://devblogs.nvidia.com/jetson-nano-ai-computing/>, accessed on 17.02.2020.
- [23] L. P. Bordignon and A. von Wangenheim, "Benchmarking deep learning models on jetson tx2."
- [24] https://en.wikipedia.org/wiki/LINPACK_benchmarks, accessed on 27.02.2020.
- [25] <https://www.top500.org/project/linpack/>, accessed on 27.02.2020.
- [26] K. S. Narendra and K. Parthasarathy, "Identification and control of dynamical systems using neural networks," *IEEE Transactions on Neural Networks*, vol. 1, no. 1, pp. 4–27, 1990.

Bijlage A

Een aanhangsel

sdfsffqsfsf

Bijlage B

Beschrijving van deze masterproef in de vorm van een wetenschappelijk artikel

Bijlage C

Poster

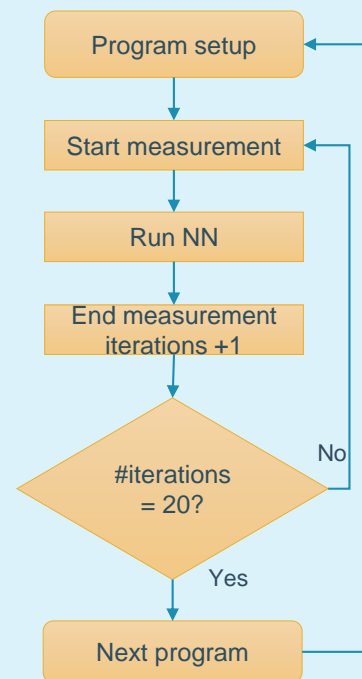

Accelerated edge computing for Neural Networks

Introduction

The deployment of self-driving vehicles is one of many new and interesting low-latency applications. To aid to lower latency during localization in position fixing, a benchmark is proposed to examine the potential of executing a trained Neural Networks (NN) or Machine Learning (ML) algorithm on edge devices like the Nvidia Jetson Nano, Google Coral Dev and Raspberry Pi 3 compared to regular computer.

Data extraction

In order to achieve a representative benchmark, it is necessary to investigate the performance of different programs on each edge device in an identical manner. In this benchmark several different programs are tested spread across categories of NN as regression and classification. For each program the duration of execution and utilization of the processor unit is measured and stored. To achieve statistically results, every program will be run for 20 different iterations.



Data analysis

To compare the performance of different edge devices, latency data will be adjusted for variables like processor usage, clock speed, price and energy usage. The results are normalised to ease a comparison.

Conclusion

The results show that non-edge devices remain superior compared to edge-devices. Among edge-devices, the Jetson Nano is the SBC with the lowest latency and price and thus an excellent choice for low-latency applications.

FACULTEIT INDUSTRIELE INGENIEURSWETENSCHAPPEN
TECHNOLOGIECAMPUS GENT
Gebroeders De Smetstraat 1
9000 GENT, België
tel. + 32 92 65 86 10
fax + 32 92 25 62 69
iiw.gent@kuleuven.be
www.iw.kuleuven.be



LID VAN **ASSOCIATIE
KU LEUVEN**